Adaptive-QuantRL: 시장 국면 적응형 PPO/SAC 앙상블 및 위험 페널티 보상 기반 동적 자산배분 통제 실증 연구

저자: 이한수 (건국대학교 컴퓨터공학 / 응용통계학)

요약 (Executive Summary)

- **연구 배경 및 목적**: 금융 시계열 기반 심층 강화학습(Deep Reinforcement Learning, DRL) 연구에서 빈번히 발생하는 ① 선행 참조 편향(Look-Ahead Bias), ② 비현실적 체결 가정, ③ 미보정 위험 페널티로 인한 정책 붕괴(Policy Collapse), ④ 평균 베타 노출(Beta Exposure) 통제 부재 문제를 해결하기 위해 엄격히 통제된 8단계 실증 프레임워크(**Adaptive-QuantRL**)를 설계 및 검증함.
- **실험 통제 프로토콜**: 2010년부터 2024년까지의 비수정(Unadjusted) SPY 일간 데이터를 대상으로 2단계 회계 체결 로직(t일 종가 관측 $\rightarrow$ $t+1$일 시가 야간 갭 반영 및 리밸런싱 체결 $\rightarrow$ $t+1$일 종가 가치 평가)과 편도 거래비용 `0.1%`(수수료 `0.05%` + 슬리피지 `0.05%`)를 강제함. 또한 관측용 로그 정규화 분산과 보상 전용 비음수 원본 분산을 분리하고, 5개 독립 난수 시드(`11, 22, 33, 44, 55`) × 2개 알고리즘(`PPO, SAC`) × 3개 보상 함수(`Reward A, B, C`) = 총 30개 독립 모델을 학습하여 표본 외(Out-of-Sample) Test 구간(`2023~2024`, 501 거래일)에서 결정론적 평가를 수행함.
- **핵심 실증 결과**: 1. **알고리즘 구조에 따른 회전율 및 성과 격차 (RQ1)**: Off-policy 엔트로피 정규화 기반의 **SAC**는 Test 전 구간 누적 거래비용을 `$189 ~ $208`로 억제하며 **CAGR `12.16%`, Sharpe `1.6317`, MDD `5.61% ~ 5.87%`**를 달성, 추세추종 기준선인 이동평균(`Moving_Average_20_50`, Sharpe `1.0219`, MDD `9.39%`)을 모든 지표에서 압도함. 반면 On-policy **PPO**는 과도한 일간 리밸런싱 회전율로 인해 누적 거래비용 `$1,078 ~ $1,131`(초기 자본 대비 약 11%)을 지출하며 Sharpe `0.33 ~ 0.54`로 성과가 잠식됨. 2. **노출 통제 기준선(Exposure-Matched Baseline) 대비 동적 앙상블 검증 (RQ2)**: Validation(2020~2022) 27개 후보 중 1위로 동결된 ADX(14) 국면 적응형 앙상블(`ADX30_S75_W25`)은 Test 구간에서 Sharpe `1.4269`, MDD `5.81%`를 기록하여 이동평균 및 단일 PPO를 크게 상회했으나, 동일한 평균 주식 노출 비중(`47.98%`)을 고정 보유하는 **Exposure-Matched Baseline(Sharpe `1.7170`, CAGR `10.97%`) 대비 Sharpe `-0.2901`, CAGR `-1.58%p` 열세**를 보임. 이를 통해 평균 베타 노출을 통제하지 않은 상태에서의 단순 벤치마크 비교가 시장 타이밍(Market Timing) 알파를 과대평가할 수 있음을 실증적으로 규명함. 3. **위험 페널티 보상의 시드별 방어 일관성 (RQ3)**: 사전 분위수 보정($\lambda_d = 0.02$)을 거친 낙폭 페널티 보상(`Reward B`)은 SAC에서 Validation 전체 1위(Sharpe `0.2753`)를 달성했을 뿐 아니라, Test 구간에서도 **5개 중 4개 시드(`4/5` Seeds)**에서 일관되게 MDD를 개선(평균 MDD `5.87%` $\rightarrow$ `5.61%`)하고 시드 간 Sharpe 표준편차를 `41%` 축소(`0.1766` $\rightarrow$ `0.1039`)함. 4. **거래비용 스트레스 테스트 강건성 (RQ4)**: 재학습 없이 편도 거래비용을 `0.1%` $\rightarrow$ `0.3%` $\rightarrow$ `0.5%`로 5배 상향한 민감도 분석에서 고회전 PPO(CAGR `-17.31%`)와 앙상블(CAGR `0.43%`)은 손익분기점이 붕괴된 반면, **SAC는 편도 `0.5%` 고비용 환경에서도 CAGR `8.45%`, Sharpe `1.1681`을 유지**하며 높은 실전 강건성을 입증함.

1. 서론 (문제 정의)

금융 포트폴리오 최적화에 심층 강화학습(DRL)을 적용하는 연구는 비선형적 시장 미시구조 특징량과 거래비용을 단일 목적함수 내에서 통합할 수 있다는 점에서 주목받아 왔다. 그러나 기존 문헌 및 다수의 퀀트 프로젝트에서는 다음과 같은 **4가지 구조적·통계적 결함**으로 인해 백테스트 성과가 과장되거나 실전 재현성이 결여되는 한계가 존재한다.

1. **선행 참조 편향(Look-Ahead Bias) 및 체결 시점 불일치**: - 전체 시계열 구간에 대해 정규화 스케일러(`StandardScaler`)를 적합하거나, t일 종가(`Close_t`)로 산출한 기술적 지표를 관측한 직후 동일한 t일 종가로 주문이 체결된다고 가정하는 오류이다. 이는 야간 갭(Overnight Gap) 위험을 제거하고 미래 가격 정보를 누수시켜 비현실적인 초과 수익을 유발한다.
2. **평균 베타 노출(Beta Exposure)과 시장 타이밍 알파(Alpha)의 혼동**: - 연속적 비중($w_t \in [0, 1]$)을 출력하는 강화학습 에이전트는 통상 평균 `40% ~ 60%` 수준의 주식 비중을 유지한다. 이를 100% 주식 보유(`Buy & Hold`)나 잦은휩소(Whipsaw)가 발생하는 단순 이동평균 교차 전략과만 비교할 경우, 에이전트의 낮은 최대낙폭(MDD)이나 준수한 Sharpe 비율이 **정교한 동적 시장 타이밍의 결과인지, 단순히 현금을 절반가량 보유한 수동적 베타 축소 효과인지 식별할 수 없다**.
3. **보상 함수 스케일 불균형 및 분산 페널티 부호 반전(Sign Inversion)**: - 일간 로그 수익률($\approx 10^{-3}$ 스케일)에 보정되지 않은 낙폭(Drawdown) 또는 분산(Variance) 페널티를 차감할 경우, 에이전트가 위험 페널티를 회피하기 위해 주식 비중을 `0%`(전량 현금)로 고정하는 정책 붕괴가 발생한다. - 특히 신경망 입력 안정화를 위해 표준화(Z-score)된 분산 특징량을 보상 함수의 페널티 항에 그대로 재사용하면, 변동성이 평균보다 낮은 구간에서 분산 값이 음수(< 0)가 되어 **페널티 차감($-\lambda_v \cdot \tilde{V}_t$)이 오히려 양(+)의 보상으로 작용하는 수학적 왜곡**이 발생한다.

4. **단일 시드(Single-Seed) 보고의 취약성**: - 강화학습은 가중치 초기화 및 환경 샘플링 난수 시드(Random Seed)에 따라 수렴 정책의 분산이 크다. 단일 최적 시드의 궤적만 선별 보고할 경우 알고리즘 자체의 구조적 우위와 우연한 초기화 효과를 구분할 수 없다.

본 연구는 위 4대 문제를 엔지니어링 및 실험 설계 단계에서 원천 통제하기 위해 **Adaptive-QuantRL** 파이프라인을 구축하고, On-policy 알고리즘인 **PPO(Proximal Policy Optimization)**와 Off-policy 알고리즘인 **SAC(Soft Actor-Critic)**의 행동 특성, 보상 함수 위험 페널티의 시드별 일관성, 그리고 시장 국면 적응형 앙상블의 실질적 유효성을 정량적으로 검증한다.

---

2. 강화학습 및 회계 프로토콜 수식화

2.1 부분 관측 마르코프 결정 과정(POMDP) 상태 공간 및 정규화 분리

단일 위험자산(SPY, 가격 행동 순수성 확보를 위해 배당 현금흐름을 제외한 비수정 OHLC 가격 사용)과 무위험 현금 간의 일간 동적 비중 조절 문제를 POMDP로 정의한다. 매 거래일 t의 장 마감 후 에이전트가 관측하는 상태 벡터 $s_t \in \mathbb{R}^{483}$은 과거 30거래일간의 시장 특징량 행렬($30 \times 16 = 480$차원)과 현재 포트폴리오 내부 상태 변수(3차원)를 결합하여 구성한다.

$$s_t = \left[\tilde{X}^{\text{mkt}}_{t-29:t},\ w_t^{\text{close}},\ DD_t,\ \tilde{V}^{\text{obs}}_{30,t} \right] \in \mathbb{R}^{483}$$

- **시장 특징량($\tilde{X}^{\text{mkt}}$, 16개 변수)**: 다중 주기도 수익률(`ret_1d`, `log_ret_1d`, `ret_5d`, `ret_20d`), 이동평균 이격도(`close_to_sma20`, `close_to_sma50`, `close_to_sma200`), 20일 실현 변동성(`vol_20d`), 상대강도지수(`rsi_14`), 정규화 MACD 지표(`macd_norm`, `macd_signal_norm`, `macd_hist_norm`), 정규화 평균진폭(`atr_14_norm`), 추세 강도 지표(`adx_14_scaled`, `plus_di_14`, `minus_di_14`).
- **Train 전용 스케일러 격리**: 모든 시장 특징량의 평균 및 표준편차는 오직 **Train 구간(`2010-01-01 ~ 2019-12-31`)** 데이터에서만 적합(Fit)하며, Validation 및 Test 구간에서는 고정된 Train 통계량으로 변환만 수행한다.
- **관측 분산과 보상 분산의 이원화**: 포트폴리오 일간 수익률의 최근 30일 표본 분산을 $\sigma^{2,\text{raw}}_{30,t} = \text{Var}(r^{\text{port}}_{t-29:t}) \geq 0$이라 할 때($t < 30$인 초기 구간은 0으로 정의), 상태 벡터 s_t에 주입되는 관측 전용 분산 $\tilde{V}^{\text{obs}}_{30,t}$는 분포의 비대칭성을 완화하기 위해 로그 변환 후 Train 통계량($\mu^{\ln V}_{\text{train}}, \sigma^{\ln V}_{\text{train}}$)으로 정규화한다.

$$\tilde{V}^{\text{obs}}_{30,t} = \frac{\ln\left(\sigma^{2,\text{raw}}_{30,t} + 10^{-8}\right) - \mu^{\ln V}_{\text{train}}}{\sigma^{\ln V}_{\text{train}}}$$

반면, 보상 함수 계산 시에는 정규화되지 않은 **비음수 원본 분산($\sigma^{2,\text{raw}}_{30,t} \geq 0$)**만을 직접 참조하여 페널티 부호 반전 현상을 원천적으로 방지한다.

2.2 2단계 주문 체결 및 일일 정산 회계 프로토콜 (t 종가 $\rightarrow t+1$ 시가 $\rightarrow t+1$ 종가)

에이전트가 t일 장 마감 시점의 상태 s_t를 관측하고 목표 주식 투자 비중 $a_t \in [0, 1]$을 결정하면, 실제 주문 체결은 다음 거래일($t+1$) 시가($Open_{t+1}$)에서 이루어지며, 성과 평가는 $t+1$일 종가($Close_{t+1}$) 기준으로 수행된다.

1. **t일 장 마감 총자산**:

$$Equity_t^{\text{close}} = Cash_t + Shares_t \times Close_t$$

2. **$t+1$일 장 시작 직후(리밸런싱 전) 총자산 (야간 갭 손익 선반영)**:

$$Equity_{t+1}^{\text{open,pre}} = Cash_t + Shares_t \times Open_{t+1}$$

3. **$t+1$일 시가 기준 목표 비중 리밸런싱 및 편도 거래비용 차감**: - 리밸런싱 전 보유 주식 평가액: $S_{t+1}^{\text{pre}} = Shares_t \times Open_{t+1}$ - 목표 주식 평가액: $S_{t+1}^{\text{target}} = a_t \cdot Equity_{t+1}^{\text{open,pre}}$ - 거래 회전 금액(Notional Turnover) 및 거래비용(편도 비용률 $c = 0.0010$, 수수료 `0.05%` + 슬리피지 `0.05%`):

$$\Delta S_{t+1} = \left| S_{t+1}^{\text{target}} - S_{t+1}^{\text{pre}} \right|, \quad Cost_{t+1} = c \cdot \Delta S_{t+1}$$

- 체결 후 주식 수 및 현금 갱신:

$$Shares_{t+1} = \frac{S_{t+1}^{\text{target}}}{Open_{t+1}}, \quad Cash_{t+1} = Equity_{t+1}^{\text{open,pre}} - S_{t+1}^{\text{target}} - Cost_{t+1}$$

4. **$t+1$일 장 마감 총자산 및 낙폭(Drawdown) 산출**:

$$Equity_{t+1}^{\text{close}} = Cash_{t+1} + Shares_{t+1} \times Close_{t+1}$$

$$Peak_{t+1} = \max\left(Peak_t,\ Equity_{t+1}^{\text{close}}\right), \quad DD_{t+1} = \frac{Peak_{t+1} - Equity_{t+1}^{\text{close}}}{Peak_{t+1}} \in [0, 1]$$

모든 스텝에서 총자산 회계 항등식과 비용 1회 차감 무결성은 단위 테스트(`pytest`)를 통해 검증된다.

2.3 보상 함수(Reward A, B, C) 수식화 및 사전 스케일 보정

위험 페널티의 단계별 효과를 분리 검증(Ablation Study)하기 위해 3가지 보상 함수를 정의한다.

$$\begin{aligned} R_{A,t} &= \ln\left(\frac{Equity_{t+1}^{\text{close}}}{Equity_t^{\text{close}}}\right) && \text{(일간 로그 수익률 단독)} \\ R_{B,t} &= R_{A,t} - \lambda_d \cdot DD_{t+1} && \text{(낙폭 페널티 추가)} \\ R_{C,t} &= R_{B,t} - \lambda_v \cdot \sigma_{30,t+1}^{2,\text{raw}} && \text{(낙폭 + 30일 원본 분산 페널티 추가)} \end{aligned}$$

- **사전 스케일 보정(Pre-Training Calibration)**: 본 학습에 앞서 Train 환경에서 3종 기준 정책(`Buy & Hold` , `Fixed 50:50` , `Random Policy`)으로 각 10개 에피소드(252일)를 시뮬레이션하여 보상 구성요소의 경험적 분포를 측정함.
- 측정 결과, 통합 일간 로그 수익률 절대값 평균은 $\mathbb{E}[|R_A|] = 0.004285$(중앙값 `0.002502`), 평균 낙폭은 $\mathbb{E}[DD] = 0.024126$, 활성 구간($t \geq 30$) 평균 원본 분산은 $\mathbb{E}[\sigma_{30}^{2,\text{raw}}] = 0.00004857$로 집계됨.
- 각 위험 페널티의 평균 크기가 $\mathbb{E}[|R_A|]$ 대비 약 `11%` 수준(권장 범위 `5% ~ 35%` 의 중심부)에 위치하도록 **대표 페널티 계수를 $\lambda_d = 0.02$ (평균 페널티 비중 `11.26%`), $\lambda_v = 10.0$ (평균 페널티 비중 `11.33%`)으로 보정하여 확정**함.

---

3. 실험 설계 (8-Phase Controlled Protocol)

3.1 시계열 데이터 분할 및 에피소드 구성

- **데이터셋**: SPY 비수정 일간 OHLC 데이터 (`2009-01-01 ~ 2024-12-31` , `2009년` 데이터는 200일 이동평균 및 30일 윈도우 구성을 위한 사전 Warm-up 버퍼로만 사용하며 수익률 계산에서 제외).
- **Train 구간 (`2010-01-01 ~ 2019-12-31` , 2,515 거래일)**: 시작 시점 편향(Start-Date Bias)을 완화하기 위해 구간 내 무작위 시점에서 시작하는 **고정 252 거래일(1년)** 에피소드로 학습 수행. 매 에피소드 시작 시 초기 자본 `$10,000` (현금 100%, 주식 0주, $DD_0 = 0$)으로 초기화.
- **Validation 구간 (`2020-01-01 ~ 2022-12-31` , 755 거래일)**: 팬데믹 급락장(2020), 유동성 상승장(2021), 금리 인상기 하락장(2022)이 모두 포함된 구간으로, 보상 함수 계수 검증 및 동적 앙상블 규칙 선정·동결에만 사용.
- **Test 구간 (`2023-01-01 ~ 2024-12-31` , 501 거래일)**: 모든 모델 파라미터와 앙상블 가중치를 완전히 동결(Freeze)한 상태에서 단 1회 결정론적(Deterministic) 최종 평가를 수행하는 미관측 홀드아웃 구간.

3.2 통제된 30개 독립 모델 학습 (Track 1 & Track 2)

알고리즘 외적 요인을 완벽히 통제하기 위해 모든 모델은 동일한 네트워크 구조(`MlpPolicy` , 은닉층 `[128, 128]`), 학습률 `3e-4` , 할인율 $\gamma = 0.99$, 총 학습 스텝 `10,080` **timesteps (40 에피소드 × 252 거래일)**, 편도 비용 `0.1%` , 그리고 동일한 5개 난수 시드(`11, 22, 33, 44, 55`)를 공유한다. - **Track 1 (앙상블 탐색 트랙)**: `Reward A` × `{PPO, SAC}` × `5 Seeds` = **10개 모델** - **Track 2 (보상 Ablation 트랙)**: `{Reward B, Reward C}` × `{PPO, SAC}` × `5 Seeds` = **20개 모델** - 총 **30개 체크포인트** (`models/checkpoints/{algo}_{reward}_{seed}/`)를 독립 학습하고 정규화 메타데이터 무결성을 검증함.

3.3 ADX(14) 시장 국면 정의, 27개 동적 앙상블 탐색 및 Exposure-Matched Baseline 동결

- **국면 판별 기준**: t일 장 마감 시점의 $\text{ADX}_{14,t}$가 사전 정의된 임계값 후보 $\theta \in \{20.0, 25.0, 30.0\}$ 이상이면 **강한 추세 (`Strong_Trend`)**, 미만이면 **약한 추세(`Weak_Trend`)**로 분류함.
- **공유 환경 Action-Level 동적 앙상블**: 동일 시드 s로 학습된 Track 1의 `PPO_Reward_A` 와 `SAC_Reward_A` 가 단일 공유 `TradingEnv` 의 상태 s_t를 동시에 관측하고, 각자의 결정론적 행동 $a_t^{\text{ppo}}(s), a_t^{\text{sac}}(s)$를 국면별 가중치로 선형 결합함.

$$a_t^{\text{ens}}(s) = w_{\text{regime}}^{\text{ppo}} \cdot a_t^{\text{ppo}}(s) + \left(1 - w_{\text{regime}}^{\text{ppo}}\right) \cdot a_t^{\text{sac}}(s)$$

여기서 $\theta \in \{20, 25, 30\}$ (3가지) × 강한 추세 PPO 가중치 $w_{\text{strong}}^{\text{ppo}} \in \{0.25, 0.50, 0.75\}$ (3가지) × 약한 추세 PPO 가중치 $w_{\text{weak}}^{\text{ppo}} \in \{0.25, 0.50, 0.75\}$ (3가지) = **총 27개 앙상블 규칙**을 Validation 구간에서 전수 평가함. - **선정 기준 및 노출 통제 기준선 (Exposure-Matched Baseline) 구축**: - 사전 정의된 다중 기준(1순위: 시드 평균 Sharpe 내림차순, 2순위: 시드 평균 MDD 오름차순, 3순위:

시드 간 Sharpe 표준편차 오름차순)에 따라 Validation 1위 규칙으로 **`ADX30_S75_W25`** ($\mathbf{ADX}_{14} \geq 30.0$일 때 $\mathbf{PPO\ 0.75 : SAC\ 0.25}$, $\mathbf{ADX}_{14} < 30.0$일 때 $\mathbf{PPO\ 0.25 : SAC\ 0.75}$)가 선정 및 동결됨(Val 평균 Sharpe `0.2267`, 평균 MDD `18.98%`). - 동결된 앙상블이 Validation 기간 동안 기록한 시드별 평균 주식 노출 비중(`Seed 11: 48.26%`, `Seed 22: 53.09%`, `Seed 33: 44.60%`, `Seed 44: 45.17%`, `Seed 55: 48.76%`, **전체 평균** **`47.98%`**)을 추출하여, Test 구간 내내 해당 고정 비중만 유지하는 **`Exposure_Matched_Baseline`**으로 동결함.

---

4. 4대 연구 질문(RQ1~RQ4) 실증 분석

4.1 Validation(2020~2022) 모델 그룹 평가 및 동결 결과 (Phase 4)

Test 평가에 앞서, 변동성이 극심했던 Validation 구간(755 거래일)에서의 6개 모델 그룹(각 5 Seeds 평균) 성과는 표 1과 같다.

표 1: Validation 구간(2020~2022) 강화학습 모델 그룹별 성과 순위 (편도 비용 0.1%, 5 Seeds 평균)

순위 (Rank)	알고리즘	보상 함수	λ_d	λ_v	누적 수익률 (%)	CAGR (Mean ± Std %)	연 변동성 (%)	Sharpe (Mean ± Std)	MDD (Mean ± Std %)	평균 주식 비중 (%)	평균 거래비용 ($)
1	SAC	Reward B	0.02	0.0	**9.54**	**3.03 ± 2.77**	14.28	**0.2753 ± 0.1761**	**20.69 ± 2.36**	53.38	314.80
2	SAC	Reward C	0.02	10.0	8.95	2.86 ± 2.46	14.37	0.2647 ± 0.1577	21.32 ± 2.59	51.58	302.35
3	SAC	Reward A	0.00	0.0	8.86	2.81 ± 2.73	14.84	0.2505 ± 0.1652	21.63 ± 1.12	54.66	291.05
4	PPO	Reward B	0.02	0.0	-4.39	-1.97 ± 7.70	14.75	-0.0429 ± 0.5261	22.05 ± 8.52	39.65	1,841.47
5	PPO	Reward A	0.00	0.0	-6.87	-2.40 ± 2.57	12.85	-0.1223 ± 0.1985	20.99 ± 2.60	35.34	1,766.98
6	PPO	Reward C	0.02	10.0	-7.41	-2.71 ± 4.55	13.97	-0.1544 ± 0.3669	20.97 ± 4.13	36.95	1,812.14

- Validation 구간에서 **SAC 계열(1~3위)이 PPO 계열(4~6위)을 압도**했으며, 특히 낙폭 페널티를 적용한 **`SAC_Reward_B`가 평균 Sharpe `0.2753`, 평균 MDD `20.69%`로 전체 1위**를 차지함(동 기간 SPY `Buy & Hold`의 MDD는 `34.10%`).

4.2 RQ 1: 전략적 차이 (강화학습 동적 비중 조절 vs 4대 전통적 벤치마크)

- **Test 구간(2023~2024, 501 거래일) 시장 환경 및 표본 충분성**:
- SPY(`1_Buy_and_Hold`)는 누적 수익률 `52.80%`, CAGR `23.77%`, 연 변동성 `12.88%`, Sharpe `1.7212`, MDD `10.29%`의 강한 상승장을 기록함.
- ADX 임계값 후보(`20.0`, `25.0`, `30.0`) 모두에서 강추세 거래일 수($N = 332, 216, 128$일)와 약추세 거래일 수($N = 169, 285, 373$일)가 최소 표본 기준($N \geq 30$)을 충족하여 통계적 유의성을 확보함.

표 2: Test 구간(2023~2024, 501일) 전체 전략 및 강화학습 모델 최종 성과 비교 (편도 비용 0.1%)

구분 (Category)	전략 / 모델명 (Model)	누적 수익률 (%)	CAGR (%)	연 변동성 (%)	Sharpe Ratio	Std Sharpe	평균 MDD (%)	평균 주식 비중 (%)	평균 거래비용 ($)
Traditional Benchmark	`1_Buy_and_Hold`	52.80	**23.77**	12.88	**1.7212**	0.0000	10.29	100.00	10.00
Traditional Benchmark	`2_Cash_100`	0.00	0.00	0.00	0.0000	0.0000	0.00	0.00	0.00
Traditional Benchmark	`3_Fixed_50_50`	24.05	11.45	6.43	1.7171	0.0000	5.25	50.00	13.73
Traditional Benchmark	`4_Moving_Average_20_50`	22.94	10.95	10.73	1.0219	0.0000	9.39	73.65	95.86
Exposure-Matched	`Exposure_Matched_Baseline`	22.99	10.97	6.17	1.7170	0.0003	**5.04**	47.98	13.44
Single RL Model	`PPO_Reward_A`	4.72	2.31	7.03	0.3340	0.3636	8.45	32.78	1,094.15
Reward Ablation	`PPO_Reward_B`	4.01	1.99	7.34	0.3286	0.2296	8.25	33.07	1,078.25
Reward Ablation	`PPO_Reward_C`	8.27	4.03	7.32	0.5404	0.4638	8.73	33.67	1,131.39
Single RL Model	`SAC_Reward_A`	**25.63**	**12.16**	7.26	**1.6317**	0.1766	5.87	55.04	189.00
Reward Ablation	`SAC_Reward_B`	24.11	11.48	6.93	1.6077	**0.1039**	**5.61**	52.36	207.61
Reward Ablation	`SAC_Reward_C`	24.59	11.69	6.97	1.6314	0.1522	5.79	52.75	195.49
Dynamic Ensemble	`Dynamic_Ensemble_ADX30_S75_W25`	19.54	9.39	6.43	1.4269	**0.0755**	5.81	45.27	466.21

- **실증 분석 결론**: 1. **SAC의 우수한 위험 조정 성과 및 능동형 벤치마크 극복**: `SAC_Reward_A/B/C` 는 평균 주식 비중 `52.36% ~ 55.04%` 로 운용되면서 **CAGR `11.48% ~ 12.16%`**, **Sharpe `1.6077 ~ 1.6317`**, **MDD `5.61% ~ 5.87%`** 를 기록함. 이는 전통적 능동형 규칙 기반 전략인 `4_Moving_Average_20_50` (평균 주식 비중 `73.65%`, CAGR `10.95%`, Sharpe `1.0219`, MDD `9.39%`)보다 훨씬 적은 주식 노출을 취하면서도 수익률(`+0.53%p ~ +1.21%p`), Sharpe(`+0.5858 ~ +0.6098`), MDD(`−3.52%p ~ −3.78%p`) 모든 면에서 우월한 성과를 거둠. 또한 `3_Fixed_50_50` (CAGR `11.45%`) 대비 높은 절대 수익률을 달성함과 동시에 `1_Buy_and_Hold` (MDD `10.29%`)의 최대 낙폭을 절반 수준으로 방어함. 2. **PPO vs SAC의 거래 회전율 구조적 차이**: PPO 모델들은 최근 롤아웃(252 스텝)에 의존하는 On-policy 클리핑 업데이트 특성상 일간 목표 비중이 급격히 진동하여 Test 기간 누적 회전율(Turnover)이 약 `93 ~ 124회`, 누적 거래비용이 **`$1,078.25 ~ $1,131.39`** 에 달함. 반면 리플레이 버퍼와 엔트로피 최대화 목적함수를 결합한 Off-policy SAC는 가치 함수 곡면을 매끄럽게 학습하여 누적 회전율을 `12 ~ 26회`, 누적 거래비용을 **`$189.00 ~ $207.61` (PPO의 약 1/5 수준)**로 억제하며 실전 수익성을 보전함.

4.3 RQ 2: 행동 특성 및 동적 앙상블 실효성 (Exposure-Matched Baseline 비교)

- **국면별 행동 상보성 분석**: Validation 구간 분석 결과, PPO(평균 비중 `35.34%`)와 SAC(평균 비중 `54.66%`)의 일간 행동 상관계수는 전 구간 $\rho = 0.0491$(강추세 $\mathbf{ADX} \geq 30$ 구간에서 $\rho = 0.0128$)로 매우 낮아 두 알고리즘이 독립적인 의사결정 기제를 보유함을 확인함.
- **Exposure-Matched Baseline 대비 엄밀한 귀인(Attribution) 평가**:
- 동적 앙상블(`Dynamic_Ensemble_ADX30_S75_W25`)은 Test 구간에서 **CAGR `9.39%`**, **Sharpe `1.4269`**, **MDD `5.81%`**, **시드 간 Sharpe 표준편차 `0.0755`** 를 달성하여, 단일 PPO(Sharpe `0.3340`)나 이동평균 전략(Sharpe `1.0219`) 대비 뚜렷한 성과 개선과 가장 낮은 시드 간 변동성을 보여줌.
- 그러나 평균 주식 노출 비중을 동일하게 통제한 **`Exposure_Matched_Baseline` (평균 비중 `47.98%`, CAGR `10.97%`, Sharpe `1.7170`, MDD `5.04%`, 거래비용 `$13.44`)과 비교하면 평균 Sharpe `−0.2901`, 평균 CAGR `−1.58%p` 열세**를 기록함.
- **원인 규명**: 강추세 국면($\mathbf{ADX}_{14} \geq 30$, Test 128일)에서 PPO에 `0.75` 의 가중치를 부여함에 따라 국면 전환 및 PPO 고회전 성향이 유입되었고, 이로 인해 발생한 추가 거래비용(`$466.21` vs `$13.44`)이 국면 전환 타이밍 효익을 초과 잠식함. 이는 **노출 통제 기준선을 설정하지 않을 경우 동적 앙상블의 베타 방어 효과를 시장 타이밍 알파로 오인할 수 있음**을 보여주는 핵심적인 데이터 사이언스 검증 사례임.

4.4 RQ 3: 위험 페널티의 일관성 (Reward Ablation: A vs B vs C)

표 3은 가장 우수한 성능을 보인 SAC 모델을 대상으로 5개 난수 시드(`11, 22, 33, 44, 55`) 각각에서 보상 함수 변경($R_A \rightarrow R_B \rightarrow R_C$)이 미친 영향을 개별 시드 단위로 추적한 결과이다.

표 3: SAC 보상 함수 Ablation의 5개 시드별 Test 구간 MDD, 연 변동성 및 Sharpe 비교

Seed	SAC_Reward_A MDD (%)	SAC_Reward_B MDD (%)	SAC_Reward_C MDD (%)	A -> B MDD 개선 여부	SAC_Reward_A Sharpe	SAC_Reward_B Sharpe	SAC_Reward_C Sharpe
11	**5.80**	5.95	6.06	X (`+0.15%p`)	1.6016	**1.6431**	1.5134
22	7.72	**6.56**	7.41	O **(`-1.16%p`)**	1.4177	1.4392	**1.4499**
33	4.57	4.53	**4.38**	O **(`-0.04%p`)**	**1.8908**	1.6686	1.8146
44	5.31	**5.13**	5.17	O **(`-0.18%p`)**	1.6975	1.7038	**1.7419**
55	5.95	**5.87**	5.92	O **(`-0.08%p`)**	1.5509	1.5837	**1.6372**
평균 (Mean)	5.87	**5.61**	5.79	**`4/5` Seeds 개선 (`-0.26%p`)**	**1.6317**	1.6077	1.6314
표준편차 (Std)	1.16	**0.78**	1.12	**시드 간 MDD 편차 `-33%` 축소**	0.1766	**0.1039**	0.1522

- **낙폭 페널티 효과 (`Reward A -> Reward B` , $\lambda_d = 0.02$)**:
- **SAC**: 평균 MDD가 `5.87%` → **`5.61%` (`-0.26%p`)**로 감소했으며, **5개 중 4개 시드(`4/5` Seeds: Seed 22, 33, 44, 55)**에서 일관되게 MDD가 개선됨. 특히 상대적으로 낙폭이 컸던 Seed 22의 MDD를 `7.72%` → `6.56%` (`-1.16%p`)로 크게 제어하여 시드 간 MDD 표준편차를 `1.16%` → `0.78%` 로 줄이고, 시드 간 Sharpe 표준편차 역시 `0.1766` → **`0.1039` (`41%` 감소)**로 안정화함.
- **PPO**: 평균 MDD가 `8.45%` → `8.25%` (`-0.20%p`)로 감소했으나 시드별 개선 비율은 `2/5` Seeds에 머무름.
- **분산 페널티 추가 효과 (`Reward B -> Reward C` , $\lambda_v = 10.0$)**:
- **PPO**: 연 변동성이 `7.34%` → `7.32%` (`-0.02%p` , `2/5` Seeds 개선)로 소폭 감소하며 평균 Sharpe가 `0.3286` → `0.5404` 로 향상됨.
- **SAC**: 연 변동성이 `6.93%` → `6.97%` (`+0.04%p` , `3/5` Seeds 개선/유지)로 유사한 수준을 유지함. 이미 엔트로피 정규화로 인해 낮은 변동성을 유지하는 SAC에서는 `Reward B` (낙폭 페널티 단독)만으로도 충분한 하방 위험 통제 효과가 달성됨을 확인함.

4.5 RQ 4: 재현성 및 거래비용 민감도 분석 (편도 0.1%, 0.3%, 0.5%)

편도 거래비용 `0.1%` 에서 학습 및 동결된 정책 파라미터를 그대로 고정한 상태에서, Test 평가 환경의 편도 거래비용만 `0.3%` (3배) 및 `0.5%` (5배)로 상향하여 전략의 손익분기 한계(Break-even Threshold)를 검증함(표 4).

표 4: 편도 거래비용 변화(0.1%, 0.3%, 0.5%)에 따른 Test 구간 성과 및 벤치마크 대비 초과 Sharpe 민감도

편도 비용 (%)	전략 / 모델 (Model)	평균 CAGR (%)	평균 Sharpe	평균 MDD (%)	평균 거래비용 ($)	vs `Fixed_50_50` 초과 Sharpe	vs `Exp_Matched` 초과 Sharpe	vs `MA_20_50` 초과 Sharpe
0.1%	`3_Fixed_50_50`	11.45	1.7171	5.25	13.73	0.0000	+0.0001	+0.6952
0.1%	`4_Moving_Average_20_50`	10.95	1.0219	9.39	95.86	-0.6952	-0.6951	0.0000
0.1%	`Exposure_Matched_Baseline`	10.97	1.7170	5.04	13.44	-0.0001	0.0000	+0.6951
0.1%	`PPO_Reward_A`	2.31	0.3340	8.45	1,094.15	-1.3831	-1.3830	-0.6879
0.1%	`SAC_Reward_A`	**12.16**	**1.6317**	5.87	189.00	-0.0854	-0.0853	**+0.6098**
0.1%	`SAC_Reward_B`	11.48	1.6077	**5.61**	207.61	-0.1094	-0.1093	**+0.5858**
0.1%	`Dynamic_Ensemble_ADX30_S75_W25`	9.39	1.4269	5.81	466.21	-0.2902	-0.2901	**+0.4050**
0.3%	`3_Fixed_50_50`	11.30	1.6969	5.27	41.14	0.0000	+0.0006	+0.7600
0.3%	`4_Moving_Average_20_50`	9.94	0.9369	9.75	285.18	-0.7600	-0.7594	0.0000
0.3%	`Exposure_Matched_Baseline`	10.83	1.6963	5.06	40.28	-0.0006	0.0000	+0.7594
0.3%	`PPO_Reward_A`	-8.00	-1.1851	18.09	2,956.81	-2.8820	-2.8814	-2.1220
0.3%	`SAC_Reward_A`	**10.29**	**1.4000**	6.19	556.58	-0.2969	-0.2963	**+0.4631**
0.3%	`SAC_Reward_B`	9.42	1.3411	**6.01**	610.14	-0.3558	-0.3552	**+0.4042**
0.3%	`Dynamic_Ensemble_ADX30_S75_W25`	4.81	0.7559	6.65	1,339.03	-0.9410	-0.9404	-0.1810
0.5%	`3_Fixed_50_50`	11.16	1.6765	5.29	68.49	0.0000	+0.0011	+0.8259
0.5%	`4_Moving_Average_20_50`	8.95	0.8506	10.12	471.35	-0.8259	-0.8248	0.0000
0.5%	`Exposure_Matched_Baseline`	10.69	1.6754	5.08	67.06	-0.0011	0.0000	+0.8248
0.5%	`PPO_Reward_A`	-17.31	-2.6041	32.64	4,458.73	-4.2806	-4.2795	-3.4547
0.5%	`SAC_Reward_A`	**8.45**	**1.1681**	6.54	910.71	-0.5084	-0.5073	**+0.3175**
0.5%	`SAC_Reward_B`	7.42	1.0741	**6.42**	996.37	-0.6024	-0.6013	**+0.2235**
0.5%	`Dynamic_Ensemble_ADX30_S75_W25`	0.43	0.0852	8.38	2,138.26	-1.5913	-1.5902	-0.7654

- **거래비용 민감도 분석 결론**: 1. **SAC의 비용 저항성 입증**: 편도 거래비용이 `0.5%`(왕복 `1.0%`)라는 극단적 마찰 환경으로 치솟더라도 `SAC_Reward_A/B/C` 는 모두 **CAGR** `7.42% ~ 8.45%`, **Sharpe** `1.0741 ~ 1.1681`, **MDD** `6.42% ~ 6.54%` 를 유지하며, 모든 비용 구간(`0.1%`, `0.3%`, `0.5%`)에서 능동형 이동평균 벤치마크(`4_Moving_Average_20_50`) 대비 양(+)의 초과 Sharpe(`+0.6098` → `+0.4631` → `+0.3175`)를 일관되게 달성함. 2. **고회전 전략의 임계점 분석**: 반면 `PPO` 계열은 편도 비용 `0.3%` 구간에서 즉시 수익률이 음수(CAGR `-8.00%`, 누적 비용 `$2,956.81`)로 붕괴하며, `Dynamic_Ensemble` 역시 `0.1%` 에서는 이동평균 전략을 상회(`+0.4050` Sharpe)했으나 `0.3%` 이상에서는 PPO의 회전율 비용이 증폭되며 이동평균 전략 대비 열세(`-0.1810` Sharpe)로 전환됨.

---

5. 한계점 및 결론

5.1 연구의 한계점 (Limitations) 및 향후 과제

1. **배당 현금흐름 제외(Price Return 기준)**: 본 연구는 순수 가격 변동과 에이전트의 리밸런싱 행동 분석에 집중하기 위해 배당이 제외된 비수정(Unadjusted) SPY 가격을 사용하였다. 모든 벤치마크와 강화학습 모델에 동일한 조건이 적용되어 상대적 비교의 공정성은 유지되나, 배당 재투자를 포함한 총수익률(Total Return) 지수 적용 시 절대적인 CAGR 수치는 상향 조정될 수 있다.
2. **단일 자산 및 강세장 표본 편향**: Test 평가 구간(`2023~2024`)은 SPY가 연평균 `23.77%` 상승하고 최대 낙폭이 `10.29%` 에 불과했던 저변동성 상승장 국면이다. 이러한 환경에서는 현금 버퍼를 보유하는 모든 위험 관리형 전략이 100% 주식 보유(`Buy & Hold`)나 거래비용이 거의 없는 고정 비중 전략(`Fixed 50:50`, `Exposure_Matched_Baseline`) 대비 베타 드래그(Beta Drag)를 겪게 된다. 향후 연구에서는 다중 자산군(채권, 원자재, 섹터 ETF)으로 행동 공간을 확장하고, 장기 하락장이 포함된 롤링 워크포워드(Rolling Walk-Forward) 검증을 수행할 필요가 있다.
3. **명시적 회전율 페널티(Turnover Penalty) 도입 필요성**: On-policy PPO가 보인 과도한 거래비용 누수를 억제하기 위해, 보상 함수 내에 $|\Delta w_t|$에 비례하는 명시적 거래 회전율 억제 항을 추가하거나 행동 변화율 제약(Action Smoothing)을 결합하는 후속 실험이 요구된다.

5.2 결론 (Conclusion)

본 연구는 데이터 누수 차단, 2단계 시가 체결 회계, 관측/보상 분산 스케일 분리, 그리고 노출 통제 기준선(`Exposure-Matched Baseline`)을 결합한 **Adaptive-QuantRL** 프레임워크를 통해 금융 강화학습의 실증적 엄밀성을 한 단계 끌어올렸다. 30개 독립 모델과 5개 난수 시드에 걸친 통제 실험 결과, **Off-policy SAC는 별도의 회전율 제약 없이도 거래비용을 효과적으로 억제하며 높은 위험 조정 성과(Sharpe `1.63`, MDD `5.61%`)와 비용 강건성을 달성**함을 입증하였다. 또한 사전 스케일 보정을 거친 낙폭 페널티(`Reward B`)가 다중 시드(`4/5` Seeds)에서 일관되게 하방 위험을 방어함을 확인하였으며, `Exposure-Matched Baseline`을 통해 동적 앙상블의 회전율 비용 잠식 원인을 투명하게 규명함으로써 신뢰할 수 있는 퀀트 연구 방법론을 제시하였다.